

Định vị vật thể tuyệt đối trong bản đồ ba chiều ngữ nghĩa cho robot giao hàng tự hành: kết hợp hướng từ cụm điểm ngữ nghĩa và khoảng cách đơn-ảnh

Nhóm nghiên cứu Hawkbots

Ngày 20 tháng 8 năm 2026

Tóm tắt

Robot giao hàng tự hành hoạt động trong nhà cần một bản đồ ba chiều (3D) có gắn nhãn ngữ nghĩa để nhận biết vị trí đối tượng và mốc tham chiếu. Báo cáo này xây dựng một hệ thống dựng bản đồ như vậy, kết hợp mô hình phát hiện đối tượng YOLO11n, mô hình tái tạo cảnh quan đơn mắt MapAnything, và một phương pháp định vị tuyệt đối vị trí đối tượng kết hợp hai tín hiệu độc lập — không dựa vào phép tam giác hoá tia camera truyền thống vốn nhạy cảm với nhiễu pose odometry của từng khung hình riêng lẻ. Tín hiệu thứ nhất là hướng (bearing), xác định từ cụm điểm ngữ nghĩa lớn nhất của đối tượng mục tiêu trong bản đồ điểm MapAnything (phân cụm bằng DBSCAN), quy đổi sang hệ tọa độ thực bằng một phép khớp toàn cục Umeyama (tỉ lệ, phép xoay, phép tịnh tiến) giữa quỹ đạo camera nội tại của MapAnything và quỹ đạo odometry, tính một lần cho toàn bộ phiên chụp — không phụ thuộc riêng một khung hình nào. Tín hiệu thứ hai là khoảng cách đơn-ảnh (monocular), ước lượng từ kích thước khung bao phát hiện được trên một khung hình duy nhất, kết hợp chiều cao thật đã biết của đối tượng và tiêu cự camera đã hiệu chỉnh — hoàn toàn độc lập với dữ liệu odometry.

Phương pháp được xác thực trên sáu phiên chụp độc lập, mỗi lần robot quan sát cùng một chậu cây theo một quỹ đạo di chuyển khác nhau, đối chiếu với số đo thực địa bằng thước dây. Kết quả định vị dao động trong khoảng 2,76 m – 3,26 m (trung bình 3,02 m, độ lệch chuẩn 0,19 m), khớp sát giá trị đo thực địa (3,00 m), sai số trung bình khoảng 6%. Phân tích tương quan cho thấy độ chính xác không đến từ độ tin cậy phát hiện 2D hay kích thước cụm điểm, mà từ việc tách bạch cả hai tín hiệu khỏi pose odometry của từng khung hình đơn lẻ.

Báo cáo cũng phân tích các giới hạn phần cứng hiện tại của nền tảng (độ phân giải camera thấp, năng lực tính toán tại biên hạn chế) làm cơ sở cho các lựa chọn thiết kế phương pháp, cùng các hướng phát triển tiếp theo.

Từ khoá: bản đồ ba chiều ngữ nghĩa, định vị đối tượng, MapAnything, YOLO, robot giao hàng tự hành, khớp toàn cục Umeyama, khoảng cách đơn-ảnh.

1 Giới thiệu

Robot giao hàng tự hành hoạt động trong nhà cần xây dựng và duy trì một bản đồ ba chiều có gắn nhãn ngữ nghĩa (semantic 3D map) nhằm nhận biết vị trí các đối tượng và mốc tham chiếu trong môi trường — ví dụ hàng hoá cần giao, hoặc các vật thể cố định như chậu cây, bàn ghế, dùng làm điểm neo cho việc điều hướng. Một pipeline xử lý điển hình cho bài toán này kết hợp ba thành phần: (i) một mô hình phát hiện đối tượng hai chiều (YOLO) chạy trên từng khung hình camera, (ii) một mô hình tái tạo cảnh quan ba chiều từ ảnh đơn mắt (monocular 3D reconstruction) để khôi phục hình học của không gian, và (iii) một cơ chế xác định vị trí tuyệt đối của đối tượng trong hệ tọa độ thực

(đơn vị mét), thường dựa trên dữ liệu định vị hành trình (odometry) của robot.

Việc triển khai một hệ thống định vị đối tượng trong điều kiện thực tế — sử dụng phần cứng chi phí thấp và dữ liệu định vị hành trình (odometry) vốn tích lũy sai số theo thời gian — đặt ra câu hỏi cốt lõi về việc đâu là yếu tố thực sự chi phối độ chính xác của hệ thống, và làm thế nào để cải thiện độ tin cậy một cách hiệu quả nhất trong giới hạn tài nguyên hiện có. Trong quá trình triển khai thực nghiệm trên nền tảng robot Hawkbots (vận hành trên ROS2 Jazzy) với camera ESP32-CAM, nhóm nghiên cứu nhận thấy rằng các phương pháp định vị phụ thuộc trực tiếp vào pose (vị trí và hướng) odometry của **từng khung hình riêng lẻ** rất nhạy với nhiễu cục bộ. Bài báo này trình

bày một phương pháp định vị thay thế, kết hợp hướng suy ra từ cụm điểm ngữ nghĩa của đối tượng trong bản đồ điểm MapAnything với khoảng cách ước lượng đơn-ảnh không phụ thuộc odometry. Phương pháp được xác thực bằng số đo thực địa qua sáu phiên chụp độc lập, cho kết quả ổn định và nhất quán, mở ra một hướng thiết kế pipeline định vị ít nhạy cảm hơn với nhiễu odometry cục bộ, không đòi hỏi đầu tư thêm phần cứng.

2 Phương pháp

2.1 Nền tảng phần cứng

Bảng 1: Thông số kỹ thuật hệ thống

Thành phần	Thông số
Robot	Hawkbot, ROS2 Jazzy (container hawkbot-bringup)
Camera	ESP32-CAM, độ phân giải QVGA (320 × 240 px)
Odometry	nav_msgs/Odometry, topic /odom
Xử lý	Máy chủ GPU từ xa, kết nối qua mạng nội bộ
Phát hiện	YOLO11n (nano), huấn luyện sẵn trên COCO-80
Dựng 3D	MapAnything (facebook/map-anything)

Ma trận nội tại camera K (hiệu chỉnh bằng phương pháp bàn cờ, 74/75 ảnh hợp lệ, sai số tái chiếu trung bình 0,12 điểm ảnh):

$$K = \begin{bmatrix} 428,72 & 0 & 148,61 \\ 0 & 427,60 & 126,02 \\ 0 & 0 & 1 \end{bmatrix}$$

2.2 Hạn chế của nền tảng phần cứng hiện tại

Độ phân giải camera. Camera ESP32-CAM được cấu hình ở độ phân giải QVGA nhằm đảm bảo băng thông truyền ảnh qua mạng không dây và tốc độ khung hình ổn định. Độ phân giải thấp này giới hạn đáng kể độ chính xác định vị góc (angular precision) của mọi phương pháp dựa trên vị trí điểm ảnh. Khi đánh giá phương án dùng mã định vị ArUco 15 cm làm điểm neo tuyệt đối (Mục 4.2), một sai lệch một điểm ảnh khi xác định góc của mã, ở khoảng cách trên hai mét, đã tương ứng với sai số vị trí thực tế lên tới vài chục xăng-ti-mét.

Năng lực tính toán. ESP32-CAM không có khả năng xử lý thị giác máy tính tại chỗ; toàn bộ suy luận YOLO và MapAnything chạy trên máy chủ GPU từ xa. Pipeline hiện tại vận hành theo phương thức xử lý hậu kỳ (offline), không phải SLAM thời gian thực; việc bổ sung cơ chế hiệu chỉnh trực tuyến (đóng vòng lặp, tối ưu đồ thị tư thế toàn cục)

đòi hỏi tài nguyên tính toán mà nền tảng hiện tại chưa đáp ứng được.

Hai giới hạn trên là lý do nghiên cứu này tập trung tìm một giải pháp thuần phần mềm, không đòi hỏi nâng cấp phần cứng — phương pháp kết hợp hướng từ cụm điểm ngữ nghĩa và khoảng cách đơn-ảnh (Mục 2.4) — thay vì các hướng khắc phục bằng phần cứng bổ sung, được đề xuất là hướng phát triển trong tương lai (Mục 4.3).

2.3 Kiến trúc pipeline

Các bước xử lý được thực hiện tuần tự cho mỗi phiên chụp:

- B1. Thu thập: Robot di chuyển tự do, camera chụp liên tục (~1 khung/giây), ghi vị trí/hướng odometry từng khung vào poses.json.
- B2. Chọn khung ưu tiên: Chạy YOLO trên toàn bộ khung gốc, chọn tối đa 130 khung có đối tượng mục tiêu, lấy mẫu đều theo từng lần ghé qua.
- B3. Dựng phòng 3D: Chạy MapAnything trên khung đã chọn, gán nhãn lớp COCO cho từng điểm 3D, tạo bản đồ điểm ngữ nghĩa và quỹ đạo camera nội tại của MapAnything.
- B4. Khớp toàn cục: Umeyama fit giữa quỹ đạo MapAnything và quỹ đạo odometry $\rightarrow (s, R, t)$, tính một lần cho cả phiên chụp.
- B5. Hướng đối tượng: Lọc điểm mang nhãn lớp mục tiêu, phân cụm DBSCAN, lấy tâm cụm lớn nhất; áp phép khớp toàn cục để suy ra hướng.
- B6. Khoảng cách đối tượng: Trên một khung duy nhất, ước lượng đơn-ảnh từ chiều cao bbox YOLO, chiều cao thật, tiêu cự camera (§ 2.4).
- B7. Kết hợp: Vị trí = vị trí camera tham chiếu + hướng $\times$ khoảng cách.

Thuật toán 1 mô tả cơ chế gán nhãn ngữ nghĩa cho điểm 3D ở B3 — nền tảng cho việc xác định cụm điểm mục tiêu ở B5.

Algorithm 1 Gán nhãn ngữ nghĩa cho đám mây điểm 3D

Require: Khung hình đã chọn $\{I_1, \dots, I_n\}$; MapAnything $\mathcal{M}$; YOLO $\mathcal{Y}$

Ensure: Đám mây điểm có nhãn $\mathcal{P} = \{(x_j, l_j)\}$

```

1:  $\mathcal{P} \leftarrow \emptyset$ 
2: for  $i \leftarrow 1$  to  $n$  do
3:    $(D_i, K_i, T_i, M_i) \leftarrow \mathcal{M}(I_i)$   $\triangleright$  độ sâu, K, pose, mặt nạ
4:    $P_i \leftarrow \text{DEPTHToWORLD}(D_i, K_i, T_i)$ 
5:    $B_i \leftarrow \mathcal{Y}(I_i)$   $\triangleright (l, \text{bbox}, \text{conf})$ , lọc theo conf
6:   for mỗi pixel  $(u, v)$ ,  $M_i(u, v) = \text{true}$  do
7:      $l \leftarrow -1$   $\triangleright$  mặc định: nền
8:     for mỗi  $(l', \text{bbox}, \text{conf}) \in B_i$  do
9:       if  $(u, v) \in \text{bbox}$  then
10:         $l \leftarrow l'$ ; break
11:     end if
12:   end for
13:    $\mathcal{P} \leftarrow \mathcal{P} \cup \{(P_i(u, v), l)\}$ 
14: end for
15: end for
16: return  $\mathcal{P}$ 

```

Hạn chế của cơ chế gán nhãn. Phép kiểm tra ở dòng 8 chỉ xác định pixel có nằm trong **khung chữ nhật** 2D của YOLO hay không, không phải phân đoạn ngữ nghĩa (segmentation) cấp pixel. Điểm nền hoặc vật thể khác lọt vào khung bao cũng bị gán nhầm nhãn. Đây là lý do bước DBSCAN ở B5 là cần thiết: cụm điểm dày đặc nhất — ứng với vật thể thật, quan sát nhất quán từ nhiều góc — được tách khỏi các điểm nhiễu rải rác.

2.4 Công thức

Khớp toàn cục (Umeyama fit). Gọi $\{q_k\}$ là vị trí camera của MapAnything (chiếu xuống mặt phẳng ngang) và $\{p_k\}$ là vị trí odometry tương ứng. Phép khớp Umeyama tìm $s \in \mathbb{R}$, $R \in SO(2)$, t tối thiểu hoá:

$$(s^*, R^*, t^*) = \arg \min_{s, R, t} \sum_k \|p_k - (sRq_k + t)\|^2 \quad (1)$$

giải bằng SVD trên ma trận hiệp phương sai chéo giữa hai tập điểm đã căn giữa. Điểm x_{raw} trong không gian MapAnything quy đổi sang thực: $x_{\text{real}} = s^* R^* x_{\text{raw}} + t^*$.

Hướng. Với c_{raw} là tâm cụm điểm ngữ nghĩa lớn nhất và o là vị trí camera tham chiếu:

$$\hat{b} = \frac{(s^* R^* c_{\text{raw}} + t^*) - o}{\|(s^* R^* c_{\text{raw}} + t^*) - o\|} \quad (2)$$


Khoảng cách đơn-ảnh. Với chiều cao bbox h_{px} , chiều cao thật H , tiêu cự f_y :

$$d = \frac{f_y \cdot H}{h_{\text{px}}}, \quad x^* = o + d\hat{b} \quad (3)$$

Không đại lượng nào ở trên phụ thuộc pose odometry của một khung đơn lẻ ngoài o (chỉ để neo kết quả) — phép khớp dùng toàn bộ quỹ đạo, khoảng cách hoàn toàn không dùng odometry. Hình 1 tổng hợp trực quan toàn bộ pipeline định vị mô tả ở trên.

3 Kết quả thực nghiệm

Phương pháp được xác thực trên sáu phiên chụp độc lập (đánh số 1–6 trong bài báo này), mỗi lần robot quan sát cùng một chậu cây theo một quỹ đạo di chuyển khác nhau, đối chiếu với giá trị đo thực địa bằng thước dây (3,00 m). Hình 2 chụp trực tiếp môi trường thử nghiệm thực tế.



Hình 2: Môi trường thử nghiệm thực tế: robot Hawkbot (đơn vị hình trụ nhỏ ở giữa sàn) hoạt động trong không gian văn phòng, với chậu cây làm đối tượng mục tiêu chính.

3.1 Kết quả định lượng


Bảng 2 tổng hợp kết quả cho từng phiên chụp, kèm các chỉ số chất lượng phát hiện/phân cụm hỗ trợ: độ tin cậy phát hiện YOLO tại khung dùng để ước lượng khoảng cách, chiều cao khung bao tương ứng, và số điểm trong cụm ngữ nghĩa lớn nhất được dùng để suy ra hướng.

Cả sáu phiên chụp cho sai lệch tuyệt đối trong khoảng 2–9% so với giá trị đo thực địa, không có phiên nào lệch quá 0,26 m. Đáng chú ý, độ tin cậy phát hiện YOLO dao động khá rộng (0,63–0,90) và số điểm trong cụm ngữ nghĩa luôn ở mức rất cao (>29 700/30 000 điểm lấy mẫu, tức cụm mục tiêu chiếm hơn 99% mẫu con) — cho thấy đối tượng được MapAnything tái tạo thành một khối điểm liền mạch, ít bị phân mảnh, bất kể độ tin cậy phát hiện 2D dao động ra sao. Hình 3 trực quan hoá sai lệch của cả sáu phiên so với đường tham chiếu thực địa.

Tương quan giữa chỉ số đầu vào và sai số. Để kiểm tra xem hai chỉ số chất lượng đầu vào (độ tin cậy YOLO, số điểm cụm ngữ nghĩa) có giải thích được phần nào sai số quan sát được hay không, chúng tôi tính hệ số tương quan Pearson giữa từng chỉ số và trị tuyệt đối sai lệch trên sáu phiên chụp. Hệ số tương quan giữa độ tin cậy YOLO và sai lệch là $r = 0,34$; giữa số điểm cụm và sai lệch là $r = 0,20$ — cả hai đều yếu và không có ý nghĩa thống kê với cỡ mẫu $n = 6$. Kết quả này, dù chỉ mang tính chỉ dấu ban đầu do số phiên chụp còn hạn chế, phù hợp với kỳ vọng lý thuyết ở Mục 4.1: độ chính xác của phương pháp chủ yếu đến từ việc tách bạch hai tín hiệu khỏi pose odometry từng khung, chứ không đến từ việc phát hiện 2D có độ tin cậy cao hay cụm điểm có kích thước lớn tới đâu.

Semantic Object Localization Pipeline — HawkBot


Combines a bearing derived from the MapAnything semantic point cluster with a monocular distance estimate — no step in this path requires a single frame's pose to be accurate.




Hình 1: Pipeline định vị đối tượng bằng hướng từ cụm điểm ngữ nghĩa MapAnything kết hợp khoảng cách đơn-ảnh.

Bảng 2: Kết quả định vị chậu cây qua sáu phiên chụp độc lập, kèm chỉ số chất lượng đầu vào

Phiên chụp	Khoảng cách ước lượng	Sai lệch so thực địa	Độ tin cậy YOLO	Chiều cao bbox (px)	Số điểm cụm ngữ nghĩa
1	2,77 m	-7,6%	0,63	192,9	29 841
2	2,76 m	-8,1%	0,90	193,9	29 992
3	3,13 m	+4,2%	0,78	170,9	29 974
4	3,08 m	+2,6%	0,65	173,6	29 773
5	3,26 m	+8,5%	0,76	164,2	29 913
6	3,12 m	+3,9%	0,76	171,4	30 000
Trung bình		3,02 m			Độ lệch chuẩn 0,19 m (6,2%)



Hình 3: Khoảng cách ước lượng của sáu phiên chụp độc lập, đối chiếu đường đo thực địa 3,00 m (nét đứt). Dải to nhất là khoảng ± 1 độ lệch chuẩn quanh giá trị trung bình.




Hình 5: Quỹ đạo camera (đường liền, ô vuông = điểm xuất phát) và vị trí chậu cây ước lượng (tam giác + đường đứt, cao 1,25 m — chiều cao thật của cây) của sáu phiên chụp, mỗi phiên trong hệ toạ độ riêng gốc tại điểm xuất phát.

3.2 Trực quan hoá trên bản đồ điểm

Hình 4 minh hoạ vị trí đối tượng định vị được (marker xanh lá, kèm khoảng cách ước lượng) cùng quỹ đạo robot (đường đỏ) trên bản đồ điểm đám mây tương ứng của cả sáu phiên chụp. Hình 5 tổng hợp cả sáu quỹ đạo và vị trí ước lượng trong một khung nhìn ba chiều duy nhất (mỗi phiên chụp giữ hệ toạ độ riêng, gốc tại điểm xuất phát), cho thấy trực quan mức độ hội tụ của sáu kết quả độc lập quanh cùng một khoảng cách.

Kết quả sáu lần đo hội tụ chặt quanh giá trị đo thực địa, sai số trung bình khoảng 6%, không phụ thuộc rõ rệt vào hình dạng quỹ đạo cụ thể của từng phiên (Hình 5) hay độ tin cậy phát hiện 2D (Bảng 2)



Hình 4: Vị trí chậu cây định vị được (marker xanh lá, nhãn “Cây”) và quỹ đạo robot (đường đỏ, nhãn “Xuất phát” tại điểm bắt đầu) trên bản đồ điểm đám mây MapAnything, cho sáu phiên chụp độc lập.

— phù hợp với lập luận ở Mục 4.1 rằng độ ổn định của phương pháp đến từ việc tách bạch hai tín hiệu hướng và khoảng cách khỏi pose odometry từng khung.

4 Thảo luận

4.1 Vì sao phép khớp toàn cục ổn định hơn tam giác hoá theo từng khung hình

Cả hai tín hiệu cấu thành phương pháp (hướng và khoảng cách) đều tránh phụ thuộc vào pose odometry của một khung hình đơn lẻ. Phép khớp Umeyama xác định hướng dựa trên toàn bộ quỹ đạo camera trong một phiên chụp — một vài khung có pose nhiễu cục bộ chỉ đóng góp một phần nhỏ vào phép khớp bình phương tối thiểu trên toàn quỹ đạo, thay vì quyết định trực tiếp kết quả như trong các phương pháp bắn tia từ pose từng khung. Khoảng cách đơn-ảnh tách biệt hoàn toàn khỏi odometry, chỉ phụ thuộc kích thước hình học của đối tượng trong một khung và thông số nội tại camera đã hiệu chỉnh sẵn. Sự kết hợp này giải thích vì sao kết quả trên sáu phiên chụp độc lập hội tụ chặt quanh giá trị đo thực địa dù mỗi lần robot di chuyển theo một quỹ đạo khác nhau.

4.2 Các hướng khắc phục bằng phần cứng đã thử nghiệm và chưa khả thi

- ArUco: mã 15 cm dán cố định làm điểm neo. Với camera QVGA, ở khoảng cách trên 2 m hoặc góc nhìn xiên, solvePnP cho sai số 0,3 m – 0,7 m — lớn ngang hoặc hơn độ trôi cần sửa.
- EKF (**/odometry/filtered**): bộ lọc Kalman mở rộng kết hợp IMU, nhưng hiệp phương sai phân kỳ đến giá trị phi vật lý ($\sim 10^{22}$), chưa khả dụng nếu không điều chỉnh sâu hơn.

4.3 Hạn chế

Nghiên cứu dựa trên sáu phiên chụp, một môi trường phòng đơn, một loại đối tượng mục tiêu (chậu cây) — chưa đủ đa dạng để khẳng định khả năng tổng quát hoá. Khoảng cách đơn-ảnh đòi hỏi biết trước chiều cao thật của đối tượng — hợp lý cho mốc tham chiếu cố định, không áp dụng trực tiếp cho vật thể kích thước thay đổi. Độ chính xác của khớp toàn cục phụ thuộc quỹ đạo có đủ đa dạng hình học; quỹ đạo quá ngắn hoặc gần thẳng có thể khiến phép khớp kém tin cậy hơn. Mở rộng loại đối tượng, số phiên chụp, và môi trường thử nghiệm là hướng phát triển ưu tiên. Về dài hạn, nâng cấp độ phân giải camera và năng lực tính toán biên (Mục 2.2) sẽ mở ra các phương án khắc

phục triết để hơn.

5 Kết luận

Bài báo trình bày một phương pháp định vị tuyệt đối vị trí đối tượng trong bản đồ ba chiều ngữ nghĩa cho robot giao hàng tự hành, kết hợp hướng suy ra từ cụm điểm ngữ nghĩa (quy đổi bằng phép khớp toàn cục trên toàn bộ quỹ đạo) và khoảng cách đơn-ảnh từ một khung hình duy nhất, hoàn toàn không phụ thuộc odometry. Đặc điểm cốt lõi là không có bước nào đòi hỏi pose của một khung hình đơn lẻ phải chính xác tuyệt đối. Xác thực trên sáu phiên chụp độc lập, phương pháp cho kết quả định vị dao động 2,76 m – 3,26 m (trung bình 3,02 m, độ lệch chuẩn 0,19 m), khớp sát giá trị đo thực địa (3,00 m), sai số trung bình khoảng 6%. Kết quả cho thấy việc tách bạch tín hiệu hướng (khớp toàn cục ít nhạy nhiều cục bộ) khỏi tín hiệu khoảng cách (độc lập odometry) là một hướng thiết kế pipeline định vị hiệu quả cho nền tảng phần cứng chi phí thấp. Các giới hạn về độ phân giải camera và năng lực tính toán biên (Mục 2.2) là cơ sở hoạch định lộ trình nâng cấp và mở rộng phạm vi đối tượng mục tiêu trong các nghiên cứu tiếp theo.