

Định vị vật thể tuyệt đối trong bản đồ ba chiều ngữ nghĩa cho robot giao hàng tự hành: kết hợp hướng từ cụm điểm ngữ nghĩa và khoảng cách đơn-ảnh

Nhóm nghiên cứu Hawkbots

Ngày 21 tháng 8 năm 2026

1 Giới thiệu

Tóm tắt

Robot giao hàng tự hành hoạt động trong nhà cần một bản đồ ba chiều (3D) có gắn nhãn ngữ nghĩa để định vị đối tượng và mốc tham chiếu. Báo cáo trình bày một hệ thống kết hợp YOLO11n, mô hình tái tạo đơn mắt MapAnything, và một phương pháp định vị tuyệt đối kết hợp hai tín hiệu độc lập — thay cho phép tam giác hoá tia camera truyền thống vốn nhạy cảm với nhiễu pose odometry của từng khung hình riêng lẻ. Toàn bộ cảm biến chỉ gồm một camera đơn giá thành thấp (ESP32-CAM), không dùng camera stereo, RGB-D hay LiDAR như phần lớn hệ thống định vị đối tượng chính xác cao hiện nay — độ chính xác đến từ thiết kế thuật toán, không phải từ nâng cấp cảm biến. Tín hiệu hướng suy ra từ cụm điểm ngữ nghĩa của đối tượng (phân cụm DBSCAN), quy đổi sang tọa độ thực bằng một phép khớp toàn cục Umeyama tính một lần cho toàn quỹ đạo; tín hiệu khoảng cách đơn-ảnh ước lượng từ kích thước khung bao trên một khung hình duy nhất, độc lập hoàn toàn với odometry.

Xác thực trên mười sáu phiên chụp độc lập ở ba khoảng cách thực địa (3 m, 5 m, 7 m), phương pháp cho sai số trung bình dưới 2% ở hai mức 3 m và 5 m (độ lệch chuẩn 0,19 m và 0,22 m), nhưng bộc lộ một sai số hệ thống khoảng -11% ở 7 m — độ lệch chuẩn ở mức này lại rất nhỏ (0,07 m), cho thấy đây là thiên lệch có thể hiệu chỉnh được chứ không phải nhiễu ngẫu nhiên. Báo cáo phân tích rõ nguồn gốc thiên lệch này cùng giới hạn phần cứng hiện tại, làm cơ sở cho các lựa chọn thiết kế và hướng phát triển tiếp theo.

Từ khoá: bản đồ ba chiều ngữ nghĩa, định vị đối tượng, MapAnything, YOLO, robot giao hàng tự hành, khớp toàn cục Umeyama, khoảng cách đơn-ảnh.

Robot giao hàng tự hành hoạt động trong nhà cần xây dựng và duy trì một bản đồ ba chiều có gắn nhãn ngữ nghĩa (semantic 3D map) nhằm nhận biết vị trí các đối tượng và mốc tham chiếu trong môi trường — ví dụ hàng hoá cần giao, hoặc các vật thể cố định như chậu cây, bàn ghế, dùng làm điểm neo cho việc điều hướng. Một pipeline xử lý điển hình cho bài toán này kết hợp ba thành phần: (i) một mô hình phát hiện đối tượng hai chiều (YOLO) chạy trên từng khung hình camera, (ii) một mô hình tái tạo cảnh quan ba chiều từ ảnh đơn mắt (monocular 3D reconstruction) để khôi phục hình học của không gian, và (iii) một cơ chế xác định vị trí tuyệt đối của đối tượng trong hệ tọa độ thực (đơn vị mét), thường dựa trên dữ liệu định vị hành trình (odometry) của robot.

Việc triển khai một hệ thống định vị đối tượng trong điều kiện thực tế — sử dụng phần cứng chi phí thấp và dữ liệu định vị hành trình (odometry) vốn tích lũy sai số theo thời gian — đặt ra câu hỏi cốt lõi về việc đâu là yếu tố thực sự chi phối độ chính xác của hệ thống, và làm thế nào để cải thiện độ tin cậy một cách hiệu quả nhất trong giới hạn tài nguyên hiện có. Trong quá trình triển khai thực nghiệm trên nền tảng robot Hawkbots (vận hành trên ROS2 Jazzy) với camera ESP32-CAM, nhóm nghiên cứu nhận thấy rằng các phương pháp định vị phụ thuộc trực tiếp vào pose (vị trí và hướng) odometry của **từng khung hình riêng lẻ** rất nhạy với nhiễu cục bộ. Bài báo này trình bày một phương pháp định vị thay thế, kết hợp hướng suy ra từ cụm điểm ngữ nghĩa của đối tượng trong bản đồ điểm MapAnything với khoảng cách ước lượng đơn-ảnh không phụ thuộc odometry. Điểm đáng chú ý là toàn bộ phần cứng cảm biến chỉ gồm một camera đơn giá thành thấp (ESP32-CAM) — không dùng camera stereo, cảm biến RGB-D, hay LiDAR như phần lớn hệ thống định vị đối tượng độ chính xác cao hiện nay; độ chính xác đạt được hoàn toàn nhờ thiết kế thuật toán, không phải nhờ nâng cấp cảm biến. Phương pháp được xác thực bằng số đo thực địa qua mười sáu phiên chụp độc lập ở ba khoảng cách (3 m, 5 m, 7 m), cho kết quả ổn định và nhất quán, mở ra một hướng

thiết kế pipeline định vị ít nhạy cảm hơn với nhiễu odometry cục bộ, không đòi hỏi đầu tư thêm phần cứng.

2 Công trình liên quan

Các hệ thống định vị và dựng bản đồ đồng thời (SLAM) như ORB-SLAM [5] tối ưu từ thể camera và cấu trúc cảnh quan qua bố điều chỉnh (bundle adjustment) và đóng vòng lặp; các hệ semantic SLAM sau này như SemanticFusion [7] và Kimera [6] mở rộng thêm bước gán nhãn đối tượng (qua mạng nơ-ron tích chập) vào bản đồ hình học theo thời gian thực. Hướng tiếp cận này đòi hỏi tối ưu hoá từ thể trực tuyến, không phù hợp với nền tảng tính toán biên hạn chế của nghiên cứu này (Mục 3.2).

Phát hiện đối tượng hai chiều làm tín hiệu ngữ nghĩa phổ biến dựa trên họ mô hình YOLO, khởi nguồn từ Redmon và cộng sự [1] và phát triển đến các phiên bản gần đây như YOLO11 [2] dùng trong nghiên cứu này. Đối với tái tạo hình học ba chiều từ ảnh đơn mắt, các mô hình suy luận trực tiếp (feed-forward) như MapAnything [9] thay thế pipeline SfM/MVS truyền thống bằng một lượt suy luận duy nhất, không cần hiệu chỉnh camera đa góc.

Để quy đổi giữa không gian nội tại của mô hình tái tạo và không gian thực từ odometry, phép khớp Umeyama [3] là công cụ kinh điển cho bài toán đăng ký điểm cứng (rigid point-set registration) với tỉ lệ chưa biết; DBSCAN [4] phân cụm điểm dựa trên mật độ mà không cần biết trước số cụm, phù hợp để tách cụm ngữ nghĩa của một đối tượng khỏi nhiều gán nhãn (Thuật toán 1).

Khác với các hướng trên, phương pháp trong bài báo này không tối ưu hoá từ thể trực tuyến hay tam giác hoá tia theo từng khung hình, mà tách bạch hoàn toàn tín hiệu hướng (khớp toàn cục hậu kỳ) và khoảng cách (đơn-ảnh) khỏi pose odometry từng khung — phù hợp với ràng buộc xử lý hậu kỳ, phần cứng chi phí thấp của nền tảng Hawkbot.

3 Phương pháp

3.1 Nền tảng phần cứng

Toàn bộ hệ thống được xây dựng từ phần cứng phổ thông, giá thành thấp (Bảng 1) — không dùng camera stereo, cảm biến RGB-D, hay LiDAR như phần lớn hệ thống định vị đối tượng chính xác cao hiện nay. Lựa chọn này đặt toàn bộ gánh nặng độ chính xác lên thiết kế thuật toán, thay vì lên chất lượng cảm biến.

Bảng 1: Thông số kỹ thuật hệ thống

Thành phần	Thông số
Robot	Hawkbot, ROS2 [8] Jazzy (container hawkbot-bringup)
Camera	ESP32-CAM, độ phân giải QVGA (320 × 240 px)
Odometry	nav_msgs/Odometry, topic /odom
Xử lý	Máy chủ GPU từ xa, kết nối qua mạng nội bộ
Phát hiện	YOLO11n [1, 2] (nano), huấn luyện sẵn trên COCO-80
Dựng 3D	MapAnything [9] (facebook/map-anything)

Ma trận nội tại camera K (hiệu chỉnh bằng phương pháp bàn cờ, 74/75 ảnh hợp lệ, sai số tái chiếu trung bình 0,12 điểm ảnh):

$$K = \begin{bmatrix} 428,72 & 0 & 148,61 \\ 0 & 427,60 & 126,02 \\ 0 & 0 & 1 \end{bmatrix}$$

3.2 Hạn chế của nền tảng phần cứng hiện tại

Độ phân giải camera. Camera ESP32-CAM được cấu hình ở độ phân giải QVGA nhằm đảm bảo băng thông truyền ảnh qua mạng không dây và tốc độ khung hình ổn định. Độ phân giải thấp này giới hạn đáng kể độ chính xác định vị góc (angular precision) của mọi phương pháp dựa trên vị trí điểm ảnh. Khi đánh giá phương án dùng mã định vị ArUco 15 cm làm điểm neo tuyệt đối (Mục 5.2), một sai lệch một điểm ảnh khi xác định góc của mã, ở khoảng cách trên hai mét, đã tương ứng với sai số vị trí thực tế lên tới vài chục xăng-ti-mét.

Năng lực tính toán. ESP32-CAM không có khả năng xử lý thị giác máy tính tại chỗ; toàn bộ suy luận YOLO và MapAnything chạy trên máy chủ GPU từ xa. Pipeline hiện tại vận hành theo phương thức xử lý hậu kỳ (offline), không phải SLAM thời gian thực; việc bổ sung cơ chế hiệu chỉnh trực tuyến (đóng vòng lặp, tối ưu đồ thị từ thể toàn cục) đòi hỏi tài nguyên tính toán mà nền tảng hiện tại chưa đáp ứng được.

Hai giới hạn trên là lý do nghiên cứu này tập trung tìm một giải pháp thuần phần mềm, không đòi hỏi nâng cấp phần cứng — phương pháp kết hợp hướng từ cụm điểm ngữ nghĩa và khoảng cách đơn-ảnh (Mục 3.4) — thay vì các hướng khắc phục bằng phần cứng bổ sung, được đề xuất là hướng phát triển trong tương lai (Mục 5.3).

3.3 Kiến trúc pipeline

Các bước xử lý được thực hiện tuần tự cho mỗi phiên chụp:

Ba khối xử lý cốt lõi của pipeline là: (i) dựng bản đồ 3D bằng MapAnything (B3), (ii) gán nhãn ngữ

nghĩa YOLO lên bản đồ 3D để có đám mây điểm ngữ nghĩa (B4), và (iii) ước lượng khoảng cách đơn-ảnh (B7) — hai tín hiệu (ii) và (iii) sau đó được kết hợp mà không cần tam giác hoá qua nhiều khung hình.

- B1. Thu thập: Robot di chuyển tự do, camera chụp liên tục (~ 1 khung/giây), ghi vị trí/hướng odometry từng khung vào poses .json.
- B2. Chọn khung ưu tiên: Chạy YOLO trên toàn bộ khung gốc, chọn tối đa 130 khung có đối tượng mục tiêu, lấy mẫu đều theo từng lần ghé qua.
- B3. Dựng bản đồ 3D: Chạy MapAnything [9] trên khung đã chọn, tái tạo đám mây điểm hình học thuần túy (chưa có nhãn) và quỹ đạo camera nội tại của MapAnything.
- B4. Gán nhãn ngữ nghĩa (YOLO $\rightarrow$ 3D): Chạy YOLO trên từng khung, gán nhãn lớp COCO cho mỗi điểm 3D theo khung bao chứa nó (Thuật toán 1), tạo **đám mây điểm ngữ nghĩa**.
- B5. Khớp toàn cục: Umeyama fit giữa quỹ đạo MapAnything và quỹ đạo odometry $\rightarrow (s, R, t)$, tính một lần cho cả phiên chụp.
- B6. Hướng đối tượng: Lọc điểm mang nhãn lớp mục tiêu trong đám mây điểm ngữ nghĩa, phân cụm DBSCAN [4], lấy tâm cụm lớn nhất; áp phép khớp toàn cục để suy ra hướng.
- B7. Khoảng cách đối tượng: Trên một khung duy nhất, ước lượng đơn-ảnh từ chiều cao bbox YOLO, chiều cao thật, tiêu cự camera (§ 3.4).
- B8. Kết hợp: Vị trí = vị trí camera tham chiếu + hướng $\times$ khoảng cách.

Thuật toán 1 mô tả cơ chế gán nhãn ngữ nghĩa cho điểm 3D ở B4 — nền tảng cho việc xác định cụm điểm mục tiêu ở B6.

Algorithm 1 Gán nhãn ngữ nghĩa cho đám mây điểm 3D

Require: Khung hình đã chọn $\{I_1, \dots, I_n\}$; MapAnything $\mathcal{M}$; YOLO $\mathcal{Y}$
 Ensure: Đám mây điểm có nhãn $\mathcal{P} = \{(x_j, l_j)\}$

```

1:  $\mathcal{P} \leftarrow \emptyset$ 
2: for  $i \leftarrow 1$  to  $n$  do
3:    $(D_i, K_i, T_i, M_i) \leftarrow \mathcal{M}(I_i)$   $\triangleright$  độ sâu, K, pose, mặt nạ
4:    $P_i \leftarrow \text{DEPTHToWORLD}(D_i, K_i, T_i)$ 
5:    $B_i \leftarrow \mathcal{Y}(I_i)$   $\triangleright (l, \text{bbox}, \text{conf})$ , lọc theo conf
6:   for mỗi pixel  $(u, v)$ ,  $M_i(u, v) = \text{true}$  do
7:      $l \leftarrow -1$   $\triangleright$  mặc định: nền
8:     for mỗi  $(l', \text{bbox}, \text{conf}) \in B_i$  do
9:       if  $(u, v) \in \text{bbox}$  then
10:         $l \leftarrow l'$ ; break
11:     end if
12:   end for
13:    $\mathcal{P} \leftarrow \mathcal{P} \cup \{(P_i(u, v), l)\}$ 
14: end for
15: end for
16: return  $\mathcal{P}$ 
```

Hạn chế của cơ chế gán nhãn. Phép kiểm tra ở dòng 8 chỉ xác định pixel có nằm trong **khung chữ nhật** 2D của YOLO hay không, không phải phân

đoạn ngữ nghĩa (segmentation) cấp pixel. Điểm nền hoặc vật thể khác lọt vào khung bao cũng bị gán nhầm nhãn. Đây là lý do bước DBSCAN ở B6 là cần thiết: cụm điểm dày đặc nhất — ứng với vật thể thật, quan sát nhất quán từ nhiều góc — được tách khỏi các điểm nhiễu rải rác.

3.4 Công thức

Khớp toàn cục (Umeyama fit) [3]. Gọi $\{q_k\}$ là vị trí camera của MapAnything (chiều xuống mặt phẳng ngang) và $\{p_k\}$ là vị trí odometry tương ứng. Phép khớp Umeyama tìm $s \in \mathbb{R}$, $R \in SO(2)$, t tối thiểu hoá:

$$(s^*, R^*, t^*) = \arg \min_{s, R, t} \sum_k \|p_k - (sRq_k + t)\|^2 \quad (1)$$

giải bằng SVD trên ma trận hiệp phương sai chéo giữa hai tập điểm đã căn giữa. Điểm x_{raw} trong không gian MapAnything quy đổi sang thực: $x_{\text{real}} = s^* R^* x_{\text{raw}} + t^*$.

Hướng. Với c_{raw} là tâm cụm điểm ngữ nghĩa lớn nhất và o là vị trí camera tham chiếu:

$$\hat{b} = \frac{(s^* R^* c_{\text{raw}} + t^*) - o}{\|(s^* R^* c_{\text{raw}} + t^*) - o\|} \quad (2)$$

Khoảng cách đơn-ảnh. Với chiều cao bbox h_{px} , chiều cao thật H , tiêu cự f_y :

$$d = \frac{f_y \cdot H}{h_{\text{px}}}, \quad x^* = o + d \hat{b} \quad (3)$$

Nhập nhằng khoảng cách–kích thước. Công thức (3) giả định biết trước H cho lớp mục tiêu. Nếu tồn tại hai vật thể cùng lớp với chiều cao thật $H_1 \neq H_2$, đặt ở hai khoảng cách d_1, d_2 sao cho


$$\frac{H_1}{d_1} = \frac{H_2}{d_2} \left(= \frac{h_{\text{px}}}{f_y} \right), \quad (4)$$

hai vật cho cùng h_{px} trên ảnh và công thức (3) không thể phân biệt được — đây là nhập nhằng khoảng cách–kích thước (scale–distance ambiguity) kinh điển của thị giác đơn mắt, không giải được từ một ảnh tĩnh duy nhất dù bằng công thức hình học hay mô hình học sâu (Mục 5.1 phân tích thêm tại sao suy luận độ sâu của MapAnything cũng không tự động thoát khỏi giới hạn này). Bước phân cụm DBSCAN ở B6, ưu tiên cụm điểm dày đặc/bền vững nhất qua nhiều khung hình, giảm thiểu nguy cơ nhầm với vật giả chỉ xuất hiện thoáng qua, nhưng không loại trừ nhầm lẫn giữa hai thực thể **thật** cùng lớp — phương pháp ngầm giả định môi trường chỉ có một thực thể của lớp mục tiêu, đúng với thiết lập thực nghiệm hiện tại (Mục 5.3).

Không đại lượng nào ở trên phụ thuộc pose odometry của một khung đơn lẻ ngoài o (chỉ để neo kết quả) — phép khớp dùng toàn bộ quỹ đạo, khoảng cách hoàn toàn không dùng odometry. Hình 1 tổng hợp trực quan toàn bộ pipeline định vị mô tả ở trên, gồm đủ ba khối (i) dựng bản đồ 3D, (ii) gán nhãn ngữ nghĩa YOLO, và (iii) ước lượng khoảng cách.

Semantic Object Localization Pipeline — HawkBot

Combines a bearing derived from the MapAnything semantic point cluster with a monocular distance estimate — no step in this path requires a single frame's pose to be accurate.



Hình 1: Pipeline định vị đối tượng bằng hướng từ cụm điểm ngữ nghĩa MapAnything kết hợp khoảng cách đơn-ảnh.

4 Kết quả thực nghiệm

Với mỗi phiên chụp, ba khối xử lý ở Mục 3.4 được thực hiện tuần tự: (i) dựng bản đồ 3D thuần hình học bằng MapAnything, (ii) gán nhãn YOLO lên từng điểm 3D để có đám mây điểm ngữ nghĩa, và (iii) ước lượng khoảng cách đơn-ảnh — hai tín hiệu hướng (suy ra từ (ii)) và khoảng cách (từ (iii)) sau đó được kết hợp thành vị trí tuyệt đối. Phương pháp được xác thực trên sáu phiên chụp độc lập (đánh số 1-6 trong bài báo này), mỗi lần robot quan sát cùng một chậu cây theo một quỹ đạo di chuyển khác nhau, đối chiếu với giá trị đo thực địa bằng thước dây (3,00 m). Để đánh giá độ ổn định khi mở rộng phạm vi hoạt động, quy trình còn được lặp lại thêm ở hai khoảng cách xa hơn — 5 m và 7 m, năm phiên chụp độc lập mỗi mức — tổng hợp cùng kết quả 3 m ở Bảng 2 và phân tích riêng ở Mục 4.4. Hình 2 minh họa trước môi trường thử nghiệm qua một lần quét mở rộng toàn bộ căn phòng, chỉ dừng ở bước (i)-(ii) (không lọc một lớp mục tiêu để tính khoảng cách/hướng — chi tiết ở Mục 4.3); Hình 5 ở phần sau đối chiếu ảnh môi trường với một khung hình YOLO phát hiện chậu cây.



(a) Ảnh chụp thực tế



(b) Bản đồ điểm (nhìn từ trên, cùng hướng với ảnh thực tế)

Hình 2: Quét toàn bộ căn phòng: đối chiếu ảnh thực tế (trái) và bản đồ điểm 3D dựng từ 239 khung hình, nhìn từ trên xuống (phải). Marker vàng đánh dấu tâm cụm điểm lớn nhất của mỗi lớp ngữ nghĩa; đường đỏ là quỹ đạo robot.

Bảng 2: Kết quả định vị chậu cây ở ba khoảng cách thực địa (3 m: sáu phiên chụp; 5 m và 7 m: năm phiên chụp mỗi mức), kèm chỉ số chất lượng đầu vào


Khoảng cách thực địa	Phiên chụp	Ước lượng	Sai lệch so thực địa	Độ tin cậy YOLO	Chiều cao bbox (px)	Số điểm cụm ngữ nghĩa
3 m	1	2,77 m	-7,6%	0,63	192,9	29 841
	2	2,76 m	-8,1%	0,90	193,9	29 992
	3	3,13 m	+4,2%	0,78	170,9	29 974
	4	3,08 m	+2,6%	0,65	173,6	29 773
	5	3,26 m	+8,5%	0,76	164,2	29 913
	6	3,12 m	+3,9%	0,76	171,4	30 000
	Trung bình	3,02 m	Độ lệch chuẩn 0,19 m, sai lệch trung bình +0,6% (TB tuyệt đối 6,2%)			
5 m	1	4,49 m	-10,2%	0,81	119,1	29 606
	2	5,07 m	+1,4%	0,74	105,4	29 984
	3	5,00 m	+0,0%	0,85	106,9	25 826
	4	5,06 m	+1,2%	0,82	105,6	25 932
	5	5,01 m	+0,3%	0,75	106,6	22 543
	Trung bình	4,93 m	Độ lệch chuẩn 0,22 m, sai lệch trung bình -1,5% (TB tuyệt đối 2,6%)			
7 m	1	6,21 m	-11,3%	0,85	86,1	29 742
	2	6,22 m	-11,1%	0,51	85,9	29 588
	3	6,17 m	-11,9%	0,73	86,6	30 000
	4	6,34 m	-9,4%	0,71	84,3	29 662
	5	6,13 m	-12,4%	0,82	87,2	29 933
	Trung bình	6,21 m	Độ lệch chuẩn 0,07 m, sai lệch trung bình -11,2%			

4.1 Kết quả định lượng

Bảng 2 tổng hợp kết quả cho từng phiên chụp, kèm các chỉ số chất lượng phát hiện/phân cụm hỗ trợ: độ tin cậy phát hiện YOLO tại khung dùng để ước lượng khoảng cách, chiều cao khung bao tương ứng, và số điểm trong cụm ngữ nghĩa lớn nhất được dùng để suy ra hướng.

Cả sáu phiên chụp cho sai lệch tuyệt đối trong khoảng 2–9% so với giá trị đo thực địa, không có phiên nào lệch quá 0,26 m. Đáng chú ý, độ tin cậy phát hiện YOLO dao động khá rộng (0,63–0,90) và số điểm trong cụm ngữ nghĩa luôn ở mức rất cao (>29 700/30 000 điểm lấy mẫu, tức cụm mục tiêu chiếm hơn 99% mẫu con) — cho thấy đối tượng được MapAnything tái tạo thành một khối điểm liền mạch, ít bị phân mảnh, bất kể độ tin cậy phát hiện 2D dao động ra sao. Hình 3 trực quan hoá sai lệch của cả sáu phiên so với đường tham chiếu thực địa.


Tương quan giữa chỉ số đầu vào và sai số. Để kiểm tra xem hai chỉ số chất lượng đầu vào (độ tin cậy YOLO, số điểm cụm ngữ nghĩa) có giải thích được phần nào sai số quan sát được hay không, chúng tôi tính hệ số tương quan Pearson giữa từng chỉ số và trị tuyệt đối sai lệch trên sáu phiên chụp. Hệ số tương quan giữa độ tin cậy YOLO và sai lệch là $r = 0,34$; giữa số điểm cụm và sai lệch là $r = 0,20$ — cả hai đều yếu và không có ý nghĩa thống kê với cỡ mẫu $n = 6$. Kết quả này, dù chỉ mang tính chỉ dấu ban đầu do số phiên chụp còn hạn chế, phù hợp với kỳ vọng lý thuyết ở Mục 5.1: độ chính xác của phương pháp chủ yếu đến từ việc tách bạch hai tín hiệu khỏi pose odometry từng khung, chứ không đến từ việc phát hiện 2D có độ tin cậy cao hay cụm điểm có kích thước lớn tới đâu.



Hình 3: Khoảng cách ước lượng của sáu phiên chụp độc lập, đối chiếu đường đo thực địa 3,00 m (nét đứt). Dải tô nhạt là khoảng ± 1 độ lệch chuẩn quanh giá trị trung bình.

4.2 Trực quan hoá trên bản đồ điểm


Hình 6 minh hoạ vị trí đối tượng định vị được (marker xanh lá, kèm khoảng cách ước lượng) cùng quỹ đạo robot (đường đỏ) trên bản đồ điểm đám mây tương ứng của cả sáu phiên chụp. Hình 4 tổng hợp cả sáu quỹ đạo và vị trí ước lượng trong một khung nhìn ba chiều duy nhất (mỗi phiên chụp giữ hệ toạ độ riêng, gốc tại điểm xuất phát), cho thấy trực quan mức độ hội tụ của sáu kết quả độc lập quanh cùng một khoảng cách. Kết quả sáu lần đo hội tụ chặt quanh giá trị đo thực địa, sai số trung bình khoảng 6%, không phụ thuộc rõ rệt vào hình dạng quỹ đạo cụ thể của từng phiên (Hình 4) hay độ tin cậy phát hiện 2D (Bảng 2) — phù hợp với lập luận ở Mục 5.1 rằng độ ổn định của phương pháp đến từ việc tách bạch hai tín hiệu hướng và khoảng cách khỏi pose odometry từng khung. Hình 5 đối chiếu môi trường thử nghiệm thực tế với một khung hình cụ thể mà YOLO11n phát hiện được chậu cây.



Hình 4: Quỹ đạo camera (đường liền, ô vuông = điểm xuất phát) và vị trí chậu cây ước lượng (tam giác + đường đứt, cao 1,25 m — chiều cao thật của cây) của sáu phiên chụp, mỗi phiên trong hệ tọa độ riêng gốc tại điểm xuất phát.




(a) Môi trường thử nghiệm



(b) YOLO11n phát hiện chậu cây

Hình 5: Môi trường thử nghiệm thực tế (trái): robot Hawkbot (đơn vị hình trụ nhỏ ở giữa sàn) hoạt động trong không gian văn phòng, với chậu cây làm đối tượng mục tiêu chính. Phát hiện YOLO11n trên khung hình ESP32-CAM (phải), độ tin cậy 0,75.



Hình 6: Vị trí chậu cây định vị được (marker xanh lá, nhãn “Cây”) và quỹ đạo robot (đường đỏ, nhãn “Xuất phát” tại điểm bắt đầu) trên bản đồ điểm đám mây MapAnything, cho sáu phiên chụp độc lập.

4.3 Mở rộng: quét bản đồ ngữ nghĩa toàn phòng

Để kiểm tra khả năng mở rộng của pipeline ngoài kích bản định vị một vật thể mục tiêu, chúng tôi cho robot đi vòng quanh toàn bộ không gian văn phòng (239 khung hình, thay vì 130 khung tập trung quanh một vật thể như Mục 4) và chạy lại toàn bộ pipeline B1–B8 không giới hạn lớp ngữ nghĩa mục tiêu — tức vẫn (i) dựng bản đồ 3D bằng MapAnything, rồi (ii) gán nhãn YOLO lên từng điểm 3D để có đám mây điểm ngữ nghĩa, chỉ khác là không lọc theo một lớp mục tiêu duy nhất ở bước (iii) ước lượng khoảng cách/hướng. Kết quả là một bản đồ điểm 3D với 38,8 triệu điểm, trong đó YOLO11n gán nhãn cho 12 lớp COCO khác nhau. Hình 2 (Mục 4) đối chiếu ảnh chụp thực tế của căn phòng với bản đồ điểm nhìn từ trên xuống.

Bản đồ tái hiện đúng hình dạng và bố cục nội thất của căn phòng (bàn, ghế, tủ, chậu cây ở đúng vị trí tương đối). Tuy nhiên vì camera QVGA độ phân giải thấp kết hợp YOLO11n (bản nano), một số nhãn phát hiện được là kết quả nhận diện sai — ví dụ “ô tô”, “máy bay”, “đèn giao thông” hầu như không có mặt thật trong văn phòng — trùng khớp với hạn chế phần cứng đã nêu ở Mục 3.2. Kết quả này cho thấy pipeline khá quát tốt sang bài toán dựng bản đồ toàn cảnh, dù độ tin cậy gán nhãn ngữ nghĩa vẫn bị giới hạn bởi phần cứng cảm biến hiện tại.

4.4 Đánh giá độ chính xác theo khoảng cách

Sáu phiên chụp ở Mục 4 đều thực hiện ở cùng khoảng cách thực địa 3,00 m. Để kiểm tra phương pháp có còn chính xác khi đối tượng ở xa hơn hay không, chúng tôi lặp lại quy trình B1–B8 (không đổi $H = 1,25$ m, cùng chậu cây mục tiêu) tại hai khoảng cách thực địa mới: năm phiên chụp độc lập ở 5 m và năm phiên chụp độc lập ở 7 m, tổng hợp cùng Bảng 2 ở Mục 4.

Ba nhóm kết quả bộc lộ hai kiểu sai số khác nhau. Ở 3 m và 5 m, sai lệch trung bình gần như triệt tiêu (+0,6% và −1,5%) nhưng độ lệch chuẩn tương đối lớn (0,19 m và 0,22 m), với một vài phiên lệch tới −10% theo cả hai chiều — đặc trưng của **nhiều ngẫu nhiên** giữa các lần đo độc lập. Ở 7 m, ngược lại: độ lệch chuẩn rất nhỏ (0,07 m, chưa bằng một phần ba so với hai mức trên) nhưng cả năm phiên đều lệch âm nhất quán quanh −11% — đặc trưng của **sai số hệ thống** (systematic bias) chứ không phải nhiễu. Vì công thức khoảng cách đơn ảnh $d = f_y H / h_{px}$ (Mục 3.4) là một quan hệ tỷ lệ thuận đơn giản giữa d và $1/h_{px}$, một sai số hằng số tương đối trong f_y (hiệu chỉnh camera) hoặc H (chiều cao giả định của chậu cây) sẽ tạo ra đúng kiểu lệch tỷ lệ không đổi quan sát được — khả năng cao là nguyên nhân của thiên lệch −11% ở 7 m, có thể đã tồn tại tương tự nhưng bị che khuất bởi

hiệu lớn hơn ở 3 m và 5 m. Hiệu chỉnh lại f_y hoặc đo chính xác hơn H là hướng khắc phục trực tiếp, được đưa vào Mục 5.3.

5 Thảo luận

5.1 Vì sao phép khớp toàn cục ổn định hơn tam giác hoá theo từng khung hình

Cả hai tín hiệu cấu thành phương pháp (hướng và khoảng cách) đều tránh phụ thuộc vào pose odometry của một khung hình đơn lẻ. Phép khớp Umeyama xác định hướng dựa trên toàn bộ quỹ đạo camera trong một phiên chụp — một vài khung có pose nhiễu cục bộ chỉ đóng góp một phần nhỏ vào phép khớp bình phương tối thiểu trên toàn quỹ đạo, thay vì quyết định trực tiếp kết quả như trong các phương pháp bắn tia từ pose từng khung. Khoảng cách đơn-ảnh tách biệt hoàn toàn khỏi odometry, chỉ phụ thuộc kích thước hình học của đối tượng trong một khung và thông số nội tại camera đã hiệu chỉnh sẵn. Sự kết hợp này giải thích vì sao kết quả trên sáu phiên chụp độc lập hội tụ chặt quanh giá trị đo thực địa dù mỗi lần robot di chuyển theo một quỹ đạo khác nhau.

Kiểm chứng thực nghiệm: dùng thẳng vị trí 3D còn kém hơn. Để kiểm tra xem có thể bỏ qua khoảng cách đơn-ảnh và dùng thẳng vị trí ($s^*R^*c_{\text{raw}} + t^*$) suy ra từ MapAnything và phép khớp Umeyama hay không, chúng tôi tính khoảng cách **trực tiếp** $\|(s^*R^*c_{\text{raw}} + t^*) - o\|$ cho cả mười sáu phiên chụp, không dùng công thức (3). Bảng 3 đối chiếu sai lệch trung bình của hai cách tính.

Bảng 3: Sai lệch trung bình: khoảng cách đơn-ảnh (dùng trong bài) so với khoảng cách suy trực tiếp từ vị trí 3D MapAnything, không hiệu chỉnh bằng H

Khoảng cách thực địa	Đơn-ảnh (dùng trong bài)	Vị trí 3D (trực tiếp)
3 m	+0,6%	-21,9%
5 m	-1,5%	-22,2%
7 m	-11,2%	-38,4%

Ở cả ba mức khoảng cách, dùng thẳng vị trí 3D suy ra từ MapAnything cho sai lệch lớn hơn nhiều — có trường hợp cá biệt lệch tới gần -80% — so với công thức đơn-ảnh. Nguyên nhân: phép khớp Umeyama là một phép khớp **toàn cục**, tìm một bộ (s, R, t) chung tốt nhất trên trung bình cả quỹ đạo, không đảm bảo chính xác cho vị trí của một điểm cụ thể; sai số này càng lớn khi quỹ đạo có đoạn quay (nguồn gốc trôi yaw đã nêu ở Mục 3.2) làm méo hình dạng quỹ đạo MapAnything so với odometry cần khớp. Điều này cũng cho thấy suy luận độ sâu bằng mô hình học sâu của MapAnything không tự động thoát khỏi nhập nhằng khoảng cách-kích thước (Mục 3.4) — nó chỉ chuyển tham chiếu mét từ “biết trước H ”

sang “tin vào odometry”, và trong thiết lập phần cứng giá rẻ này, tham chiếu odometry hoá ra kém tin cậy hơn. Kết quả này khẳng định lựa chọn thiết kế của bài báo: dùng vị trí 3D chỉ cho **hướng** (một vector đơn vị, ít nhạy sai số tỉ lệ tổng thể) chứ không dùng cho **khoảng cách tuyệt đối** — nếu làm ngược lại, độ chính xác sẽ tệ hơn hẳn.

5.2 Các hướng khắc phục bằng phần cứng đã thử nghiệm và chưa khả thi

- ArUco: mã 15 cm dán cố định làm điểm neo. Với camera QVGA, ở khoảng cách trên 2 m hoặc góc nhìn xiên, solvePnP cho sai số 0,3 m – 0,7 m — lớn ngang hoặc hơn độ trôi cần sửa.
- EKF (/odometry/filtered): bộ lọc Kalman mở rộng kết hợp IMU, nhưng hiệp phương sai phân kỳ đến giá trị phi vật lý ($\sim 10^{22}$), chưa khả dụng nếu không điều chỉnh sâu hơn.

5.3 Hạn chế

Nghiên cứu dựa trên mười sáu phiên chụp (sáu ở 3 m, năm ở 5 m, năm ở 7 m), một môi trường phòng đơn, một loại đối tượng mục tiêu (chậu cây) — chưa đủ đa dạng để khẳng định khả năng tổng quát hoá. Khoảng cách đơn-ảnh đòi hỏi biết trước chiều cao thật của đối tượng — hợp lý cho mốc tham chiếu cố định, không áp dụng trực tiếp cho vật thể kích thước thay đổi; sai lệch hệ thống -11% quan sát được ở 7 m (Mục 4.4) cho thấy H hoặc f_y cần được hiệu chỉnh chính xác hơn khi mở rộng phạm vi khoảng cách hoạt động. Độ chính xác của phép khớp toàn cục phụ thuộc quỹ đạo có đủ đa dạng hình học; quỹ đạo quá ngắn hoặc gần thẳng có thể khiến phép khớp kém tin cậy hơn. Mở rộng loại đối tượng, số phiên chụp, và môi trường thử nghiệm là hướng phát triển ưu tiên. Về dài hạn, nâng cấp độ phân giải camera và năng lực tính toán biên (Mục 3.2) sẽ mở ra các phương án khắc phục triệt để hơn.

6 Kết luận

Bài báo trình bày một phương pháp định vị tuyệt đối vị trí đối tượng trong bản đồ ba chiều ngữ nghĩa cho robot giao hàng tự hành, kết hợp hướng suy ra từ cụm điểm ngữ nghĩa (quy đổi bằng phép khớp toàn cục trên toàn bộ quỹ đạo) và khoảng cách đơn-ảnh từ một khung hình duy nhất, hoàn toàn không phụ thuộc odometry. Đặc điểm cốt lõi là không có bước nào đòi hỏi pose của một khung hình đơn lẻ phải chính xác tuyệt đối. Xác thực trên mười sáu phiên chụp độc lập ở ba khoảng cách thực địa (3 m, 5 m, 7 m), phương pháp cho sai số trung bình dưới 2% ở 3 m và 5 m, nhưng bộc lộ sai số hệ thống khoảng -11% ở 7 m (Mục 4.4) — chỉ dấu cho thấy cần hiệu chỉnh lại chiều cao đối tượng giả định hoặc tiêu cự camera khi mở rộng phạm vi.

vi hoạt động. Kết quả cho thấy việc tách bạch tín hiệu hướng (khớp toàn cục ít nhạy nhiều cục bộ) khỏi tín hiệu khoảng cách (độc lập odometry) là một hướng thiết kế pipeline định vị hiệu quả cho nền tảng phần cứng chi phí thấp. Các giới hạn về độ phân giải camera và năng lực tính toán biên (Mục 3.2) là cơ sở hoạch định lộ trình nâng cấp và mở rộng phạm vi đối tượng mục tiêu trong các nghiên cứu tiếp theo.

Tài liệu

- [1] J. Redmon, S. Divvala, R. Girshick, A. Farhadi. “You Only Look Once: Unified, Real-Time Object Detection.” *Proc. IEEE CVPR*, 2016.
- [2] G. Jocher, A. Chaurasia, J. Qiu. *Ultralytics YOLO11*. <https://github.com/ultralytics/ultralytics>, 2024.
- [3] S. Umeyama. “Least-Squares Estimation of Transformation Parameters Between Two Point Patterns.” *IEEE Trans. Pattern Analysis and Machine Intelligence*, 13(4):376–380, 1991.
- [4] M. Ester, H.-P. Kriegel, J. Sander, X. Xu. “A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise.” *Proc. KDD*, 1996.
- [5] R. Mur-Artal, J. M. M. Montiel, J. D. Tardós. “ORB-SLAM: A Versatile and Accurate Monocular SLAM System.” *IEEE Trans. Robotics*, 31(5):1147–1163, 2015.
- [6] A. Rosinol, M. Abate, Y. Chang, L. Carlone. “Kimera: An Open-Source Library for Real-Time Metric-Semantic Localization and Mapping.” *Proc. IEEE ICRA*, 2020.
- [7] J. McCormac, A. Handa, A. Davison, S. Leutenegger. “SemanticFusion: Dense 3D Semantic Mapping with Convolutional Neural Networks.” *Proc. IEEE ICRA*, 2017.
- [8] M. Quigley, K. Conley, B. Gerkey, J. Faust, T. Foote, J. Leibs, R. Wheeler, A. Y. Ng. “ROS: an open-source Robot Operating System.” *ICRA Workshop on Open Source Software*, 2009.
- [9] Meta AI (FAIR). *MapAnything: Universal Feed-Forward 3D Reconstruction*. <https://huggingface.co/facebook/map-anything>, 2025.